

SG-Lean 思路汇报

复用引导的双尺度 Lean 4 证明器

2026 年 9 月 27 日

本项目保留 SGS 启发的两个时间尺度：在线解决单题，离线建立引理库。本次评审后不再把项目描述为 SGS 训练复现，也不把“模型写了库名”直接解释成能力提升。研究核心是验证：离线积累的形式化知识能否通过冻结引理库，以可控成本提高新目标的证明成功率。

目录

1 问题与目标	1
2 与 SGS 的关系	1
3 两个尺度与唯一接口	2
4 在线求解	2
5 离线建库	2
6 实验设计	3
7 数据纪律	3
8 外部评审发现的问题	3
9 当前状态与下一步	3
10 预期贡献	4

1 问题与目标

Lean 证明器的最终产品要求很简单：输入命题，输出一段通过内核检查的证明脚本。困难在于，语言模型每次求解往往从头开始，历史计算没有以可靠形式积累下来。

本项目尝试建立一个轻量闭环：离线从课程集发现并证明可复用引理，在线把冻结库中与当前目标相关的引理提供给模型。不训练模型、不训练检索器、零 GPU；正确性始终由 Lean 内核裁决。

主指标是冻结测试集上的严格 $\text{pass}@1$ / $\text{pass}@k$ ；成本指标包括每解出一题、每产生一条引理、每得到一条真正可复用引理所消耗的 token。


2 与 SGS 的关系

SGS 的三个角色仍提供结构启发：Solver 解题，Conjecturer 为未解目标提出合成命题，Guide 抑制低质量合成题。但是二者的能力传递方式不同：

	SGS	SG-Lean
Solver 更新	训练模型参数	参数冻结
离线积累载体	合成训练数据与权重	已证引理与冻结库快照
Guide	LLM 评审合成题	对照组保留；主方法使用跨目标复用证据
正确性	Lean 验证训练样本	Lean 验证候选引理和最终证明

因此 SG-Lean 必须重新建立自己的证据链，不能把 SGS 中“合成题推动训练”的结论直接搬过来。

3 两个尺度与唯一接口



在线与离线只通过快照相连。在线不写库；正式评测期间快照不变。这样可以清楚回答“这一版库到底有没有帮助”，也避免在线临时生成内容污染全局实验。

4 在线求解

正式方法比较采用最短路径：解析与门检、读取冻结库、相关性召回、在相关候选内按复用密度排序、生成 k 篇证明、Lean 批量终检、输出通过项。

廉价 tactic 和 repair 仍可作为产品能力，但不进入库效果的主指标。外部 Mathlib 检索在缺少稳定端点和独立消融时，也不进入核心流程。这样可以避免一个“有库/无库”实验同时改变太多因素。

5 离线建库

课程集 C 内部稳定拆为 C-build 和 C-measure。前者用于轨迹、需求和候选产生；后者用于给候选提供跨目标试用机会。候选经过合式、非平凡、新颖、可证四道硬门后进入 probation，而

不是直接进入活动库。

$$\text{reuse}(\ell) = |\{w \neq \text{source}(\ell) : \exists y, \text{verify}(w, y) = 1 \wedge \ell \in \text{constants}(y)\}|, \quad \text{score}(\ell) = \frac{\text{reuse}(\ell)}{\text{cost}(\ell)}.$$

计数必须按不同目标去重，只接受通过内核的证明项依赖；失败证明中出现库名不算，同一引理自己的来源目标也不算。

状态	含义	正式在线可见
probation	已证明，等待公平曝光	否
active	达到曝光和跨目标复用门槛	是
cold	曝光充分仍无复用证据，或已淘汰	否

reuse 只说明“被使用”，不说明“产生了因果帮助”。真实帮助必须由冻结的有库/无库配对实验测量。本项目不再把真实随机模型的 $\text{pass}@k$ 描述成具有子模近似保证。

6 实验设计

组	候选背景	选择	隔离的问题
A	真实需求	SGS Guide	与 B 比较选择判据
B	真实需求	reuse/cost	完整方法
C	随机等量伪需求	reuse/cost	与 B 比较需求信号

A/B 共用候选池，仅改变选择；B/C 保持选择和预算不变，仅改变需求背景。三组在线评测使用同一模型、温度、 k 、token 上限、检索和验证器。

正式结果同时报告严格 $\text{pass}@k$ 、配对差值和置信区间、成本、失败类型、复用分布，并抽样比较引用代理与逐引理 with/without 真实增益。

7 数据纪律

C 只用于建库；D (miniF2F valid) 只用于调参和装置检查；T (miniF2F test) 只在全部冻结后运行一次。库条目必须记录来源，D/T 来源的候选无条件拒收。当前 C=195，与 D/T 命题级重叠为 0。

现有 C2 抽样在 80 题中只有 5 条 near-miss，正式实验前需要按题面形态重选，让工作负载具有足够分辨率。

8 外部评审发现的问题

1. 现有 35 条库全部 $\text{reuse}=0$ ，且包含 $\mathbf{a}=\mathbf{a}$ 、集合基数自反等平凡命题；

2. 旧“14/24 引用”只检查生成文本是否含 `sgs_lem`，失败证明也会计数；
3. 新候选验证通过后直接进入活动库，缺少 `probation`；
4. 检索把 `reuse` 密度放在相关性之前，未来会产生曝光偏差；
5. 在线、离线和两臂脚本各有一套近似重复的求解/验证路径；
6. `cheap`、`repair`、外部检索和三个 `pass` 口径同时进入主叙事，模糊了库的真实作用；
7. `Compression`、`delta_len`、未实测 `Spearman` 和子模保证增加了概念负担但没有形成证据。

9 当前状态与下一步

可继续使用的工程基础包括 `Gate`、`Verify`、`Trace.constants`、`Materialize`、常驻 Lean 服务、数据角色守卫和逐题落盘。纯 Python 自检当前为 72 条断言。

当前 35 条库降级为开发期资产；P1 仍只有 9 题部分报告。在下列工作完成前，不运行正式 P3 或 T：

1. 统一求解、检索、验证执行引擎；
2. 把两臂引用统计改为通过证明的 Lean constants；
3. 实现 `probation/active/cold` 与冻结快照；
4. 修复非平凡门并重建正式库；
5. 分离产品提示词和中性测量提示词；
6. 重选 C2，在 D 上冻结参数后再跑 A/B/C。

10 预期贡献

项目最终贡献不应表述为“又一个自博弈训练系统”，而应是：

1. 一个零训练、零 GPU、由 Lean 内核兜底的双尺度证明器；
2. 一套把候选引理从“可证”推进到“跨目标实际使用”的库生命周期；
3. 对引用型复用代理与真实 `pass@k` 增益关系的诚实审计；
4. 同预算下 SGS Guide 与形式化复用选择的可复现实证对照。