

SG-Lean 思路文档（第二版）

复用引导的双尺度 Lean 4 证明器
外部评审后实现规格

2026 年 9 月 27 日

文件地位：本文件是当前实现规格。历史阶段日志只记录过去发生了什么，不能覆盖本规格。字段协议见 `sgs-reap/docs/api-contract.md`，数据纪律见 `sgs-reap/docs/data-protocol.md`，工程坑见 `sgs-reap/docs/pitfalls.md`。

本次重定稿的核心：保留“在线单题求解 + 离线建库”两个时间尺度，但把二者的连接收紧为一个冻结的活动库快照；区分“引理被使用”与“引理真正带来增益”；删除不成立的子模保证；将现有 35 条库降级为开发期资产。

目录

1	目标、边界与评判指标	2
1.1	产品目标	2
1.2	与 SGS 的关系	2
1.3	指标与裁决	3
2	固定架构：两个尺度，一个接口	3
2.1	总览	3
2.2	为什么要有试用池	3
3	在线单题求解规格	4
3.1	正式方法比较的核心路径	4
3.2	产品增强层	4
3.3	提示词分离	4
4	离线建库规格	5
4.1	C 的内部划分	5
4.2	一轮闭环	5
4.3	硬门	5
4.4	复用判据	5
4.5	晋升、淘汰与快照	6

5	数据协议	6
6	实验设计	7
6.1	三组对照	7
6.2	两类测量不能混	7
6.3	T 的一次性运行	7
7	实现边界与精简原则	7
7.1	一个引擎，三个调用者	7
7.2	保留、降级与删除	7
8	当前事实与迁移状态	8
8.1	可继续使用的基础	8
8.2	旧资产的正确定位	8
8.3	代码迁移清单	8
9	阶段计划与验收	8
9.1	P0: 连接正确性重构	8
9.2	P1: 语料与正式建库	9
9.3	P2: 开发集冻结	9
9.4	P3: 正式对照	9
9.5	P4: 成本、忠实度与写作	9
A	核心字段契约	9
A.1	LibraryEntry	9
A.2	LibrarySnapshot	10
A.3	严格评测记录	10

1 目标、边界与评判指标

1.1 产品目标

输入一条闭式 Lean 4 命题，输出一段通过 Lean 内核终检的 tactic 脚本。

候选必须依次通过 `Verify.verify` 和最终 `checkProof`；否则不得进入输出字段。

项目不做自然语言自动形式化，不训练或微调模型，不训练检索器，也不重造一个通用的 Mathlib 前提选择系统。研究问题是：在零训练条件下，离线构建的可复用引理库，能否以可控成本提高未参与建库目标的证明成功率？

1.2 与 SGS 的关系

本项目受 SGS (*Scaling Self-Play with Self-Guidance*) 的 Solver、Conjecturer、Guide 角色分工启发，但不是 SGS 的训练复现。原 SGS 让合成题通过训练更新 Solver；本项目的 Solver 参数始终冻结，离线积累只通过引理库传递给在线求解器。

因此不能直接继承 SGS 的因果叙事。必须单独验证以下链条：

离线候选 → 通过硬门和内核 → 跨目标真实使用 → 活动库 → 在线 pass@ k 增益。

1.3 指标与裁决

优先级	指标	口径
1	严格 pass@1 / pass@ k	目标级；首轮模型生成；无 repair、无廉价 tactic
2	成本	CostPerSolved、CostPerLemma、CostPerReusable
3	轻量化	0 可训练参数、0 GPU、单实验不超过 12 h、API 不超过 500 元


廉价 tactic 与 repair 是产品增强，不是库方法本身。它们可以启用，但必须另报 `product-pass@k`，不得覆盖严格口径。

$$\text{CostPerReusable} = \frac{\text{建库总 token}}{\#\{\ell : \text{reuse}(\ell) \geq 2\}}.$$

正确率差异显著时取正确率高者；置信区间重叠时取 CostPerSolved 更低者；成本接近时取实现更简单者。违反轻量化约束的方案直接淘汰。

2 固定架构：两个尺度，一个接口

2.1 总览



两个尺度只通过 **LibrarySnapshot** 相连。在线路径只读，不允许回写全局库；离线发布新快照后，必须记录快照哈希并重新做环境预检。正式评测期间快照冻结。

2.2 为什么要有试用池

新引理在产生时必然没有复用证据。如果要求 `reuse>0` 才接纳，库无法冷启动；如果一经证明就进入正式库，活动库又会退化成“所有可证候选的堆积”。因此库必须三态化：

状态	含义	在线可见性
probation	已通过硬门并有内核证明，等待跨目标试用	正式在线不可见
active	在非来源目标上获得足够曝光并达到复用门槛	进入冻结快照
cold	曝光充分仍无复用证据，或从 active 淘汰	不可见，保留审计

3 在线单题求解规格

3.1 正式方法比较的核心路径

1. **解析**：把声明或命题字符串转换为闭式命题；失败属于输入错误。
2. **门检**：确认能够 elaborate 且类型为 Prop；协议错误不能伪装成门检拒绝。
3. **读取快照**：校验库哈希、物化模块与 import 预检。
4. **相关性召回**：先按当前目标召回相关 active 引理。
5. **复用排序**：只在相关集合内按 reuse/cost 排序并做 token 截断。
6. **生成**：固定模型、温度、 k 与 token 上限，生成 k 篇 tactic 脚本。
7. **终检**：批量执行，检查无 sorry、无残余元变量、无未闭合目标，并交内核复核。
8. **输出和记账**：只保存通过项；记录快照哈希、候选数、严格 pass@ k 与成本。

外部 Mathlib 检索暂不进入核心流程。Mathlib 仍作为 Lean 环境和模型可调用的基础库；只有在出现稳定端点、明确成本和独立消融之后，才把外部检索作为扩展重新加入。

3.2 产品增强层

廉价 tactic 可以在模型前运行，repair 可以在首轮全部失败后运行。二者必须满足：

- 最终仍经过同一内核验证器；
- 与核心路径共用同一执行引擎，不另写一套验证逻辑；
- 报告中分开给出严格口径、cheap 增益、repair 增益和总成本；
- 库 A/B 实验默认关闭，以免混淆库效果。

3.3 提示词分离

产品提示词可以建议优先检查库引理，以提高实际求解率。测量提示词只能中性列出“这些引理可用”，不得写“优先引用”“更便宜”或“更不容易错”。否则引用率混入提示服从性，不能解释为复用证据。

4 离线建库规格

4.1 C 的内部划分

C 在保持与 D/T 隔离的前提下，按稳定哈希确定性划分：

- **C-build:** 基线求解、需求挖掘、候选生成和候选证明；
- **C-measure:** 给 probation 引理提供跨目标曝光，测量 reuse；
- 候选的 `source_target` 无论属于哪一块，都不得为自身贡献 reuse。

划分清单属于派生数据，不入库；manifest 必须记录划分算法、种子、指纹和规模。

4.2 一轮闭环

`BUILD_ROUND(C_build, C_measure, snapshot, config):`

1. solve C_build with the current frozen snapshot; collect verified traces
2. mine demands from normalized subgoals, deduplicated by target
3. conjecture candidates for unsolved C_build targets
4. hard-gate candidates: Prop, nontrivial, novel, provable
5. put verified candidates into probation, not active
6. schedule neutral, salted exposures on relevant C_measure targets
7. count constants only from kernel-accepted proofs; exclude source targets
8. promote by reuse/cost; move fully-tested failures to cold
9. materialize active entries, compile, preflight, freeze snapshot
10. persist round report and immutable snapshot manifest

4.3 硬门

门	判定	反向对照
合式	elaborate 后是 Prop	非 Prop 与缺失响应必须分别失败
非平凡	配置内的廉价 tactic 不能证明	$P=P$ 、 $x=x$ 、True 必须被拒
新颖	不与父目标或已有候选/活动库等价	改名后的重复命题必须被拒
可证	至少一篇证明通过内核终检	含 sorry、残余目标或错误常量必须被拒

证明步数、压缩长度和结构复杂度可以作为诊断字段，但不再成为第二套准入逻辑。

4.4 复用判据

对 probation 或 active 引理 ℓ ：

$$\text{reuse}(\ell) = |\{w : w \neq \text{source}(\ell), \exists y, \text{verify}(w, y) = 1 \wedge \ell \in \text{constants}(y)\}|.$$

$$\text{cost}(\ell) = \text{tokens}(\text{render}(\ell)), \quad \text{score}(\ell) = \frac{\text{reuse}(\ell)}{\text{cost}(\ell)}.$$

必须按不同目标去重; 失败证明、文本字符串命中和同一目标多次引用都不计数。每条 probation 引理至少获得规定数量的**相关目标曝光**后才能判定。曝光调度必须带轮次盐, 防止后端缓存把重复试验变成同一输出的重放。

解释边界: reuse 是“被使用次数”, 不是因果复用价值。它可用于晋升和排序, 但不能单独证明引理提高了解题率。真实价值由冻结的 with/without 配对实验测量。本项目不再声称随机模型的真实 pass@k 目标具有子模近似保证。

4.5 晋升、淘汰与快照

- **晋升:** 达到最小曝光数且 `reuse >= threshold`, 再按 `score` 和库预算取舍。
- **继续试用:** 曝光不足, 不能因 `reuse` 为 0 被淘汰。
- **冷存:** 曝光充分仍为 0, 或活动库预算下被替换; 记录原因与轮次。
- **发布:** 只物化 `active`; 编译指定模块; 预检成功后生成不可变 `snapshot manifest`。

快照至少记录版本、内容哈希、生成提交、`active` 条目列表、Lean import、模型配置、数据指纹和晋升阈值。正式评测报告只引用快照, 不引用“当前可变 JSONL”。

5 数据协议

数据	用途	禁止
C	建库; 内部拆分 C-build / C-measure	与 D/T 同源
D	miniF2F valid; 调参、debug、难度和预算选择	入库、需求挖掘、候选来源
T	miniF2F test; 冻结后一次性最终评测	任何调参、建库或试跑

判断泄漏以来源为准, 不以文本相似度为准。库条目必须带 `source_target` 与 `source_corpus`。评测时在线产生的临时内容不得回写全局库。

当前 C=195 (C1 63、C2 132), 与 D/T 命题级重叠为 0。但现有 C2 抽样在 80 题标定中只有 5 条 near-miss, 正式重建前必须按题面形态重选, 并在 D 上冻结难度和预算规则。

6 实验设计

6.1 三组对照

组	候选生成条件	选择判据	回答的问题
A	真实需求	SGS Guide	Guide 与形式化复用选择谁更好
B	真实需求	reuse/cost	完整方法
C	随机等量伪需求	reuse/cost	真实需求是否优于随机背景

A/B 必须使用同一候选池，只改变选择判据；B/C 保持选择、预算和执行配置相同，只改变需求信号。三组共享模型、温度、 k 、token 上限、硬门、曝光计划、在线检索和验证器。

6.2 两类测量不能混

1. 使用测量：从通过证明的 constants 统计 reuse，用于库生命周期。
2. 效果测量：同一目标、同一配置、冻结随机化方案下做无库/有库配对，测严格 pass@ k 差值，用于结论。

报告必须给出配对差值、置信区间、按难度分层的结果、后端和协议错误、token 成本，并抽样做逐引理 with/without 消融。引用代理与真实边际增益的 Spearman 只能作为审计，不能替代主结果。

6.3 T 的一次性运行

只有同时满足以下条件才允许运行 T：代码、超参、C 数据、库快照、评测脚本、随机种子、报告 schema 全部冻结；D 上装置检查通过；测试台账为空。结果无论好坏都如实报告。

7 实现边界与精简原则

7.1 一个引擎，三个调用者

在线 Prover、离线 Runner 和两臂实验必须调用同一个“生成 → Lean 验证 → constants 提取”执行引擎。它们可以有不同配置，不能复制 HTTP、检索、验证和引用统计实现。

顶层脚本入口仍保持五个：单题、批量评测、离线闭环、配对测量、唯一测试入口。“一个概念一条实现路径”不等于把所有代码塞进一个大文件；可以拆内部模块，但必须有一个公共 facade 和一个字段协议。

7.2 保留、降级与删除

历史日志和 archive 保留事实，但 README、AGENTS、思路文档和接口协议不得继续引用旧结论。

类别	内容
保留	Gate、Verify、Trace.constants、Materialize、常驻服务、数据守卫、Guide 对照
核心重构	统一执行引擎、库三态、冻结快照、正确两臂统计、相关性优先检索
降级扩展	cheap、repair、外部 Mathlib 检索；不进入库主实验
退出主线	Compression/delta_len、未实测的子模保证、未使用配置与重复路径

8 当前事实与迁移状态

8.1 可继续使用的基础

Gate、内核终检、证明项依赖抽取、物化编译、常驻 Lean 服务、数据角色守卫和逐题落盘已经具备。纯 Python 自检当前为 72 条断言。

8.2 旧资产的正确定位

现有 sgs-reap/experiments/library.jsonl 的 35 条全部 reuse=0，并含 a=a、集合基数自反等可由 rf1 证明的平凡条目。它是开发期装置资产，不是正式活动库。

g3_c_device_n12_k2.json 所报“14/24 引用”按生成文本是否包含 sgs_lem 统计，包含失败证明，不能作为正式 reuse 证据。

p1_dev_k4_n20.json 仍是 9 题、partial=true 的开发报告。

8.3 代码迁移清单

1. 统一在线、离线和两臂执行路径；
2. 两臂引用改为通过证明的 Lean constants；
3. 实现 probation/active/cold 和 snapshot manifest；
4. 修复非平凡硬门并加入 rf1 反例；
5. 改为相关性先召回、reuse/cost 后排序；
6. 分开产品提示词与中性测量提示词；
7. 重选 C2、重建库、再跑 D 装置检查。

迁移完成前不运行正式 P3，不运行 T。

9 阶段计划与验收

9.1 P0：连接正确性重构

交付：统一执行引擎、正确引用统计、库三态、快照协议、硬门反例测试。闸门：一条失败证明即使写了库名也不计 reuse；一条 rf1 平凡候选不能进入 probation；同一来源目标不能为自己的候选贡献 reuse。

9.2 P1: 语料与正式建库

交付：按题面形态重选 C2；稳定划分 C-build/C-measure；在 C 上重建 A/B/C 三个库。闸门：每个 active 条目均有可追踪的非来源目标引用证据和曝光记录；快照可物化、编译、预检。

9.3 P2: 开发集冻结

交付：D 上确定模型、 k 、预算、曝光数、阈值、难度层和统计方案。闸门：严格口径报告可复现；后端错误和协议错误不进入失败分母；配置写入冻结清单。

9.4 P3: 正式对照

先在 D 上运行 A/B/C；框架完全冻结后，在 T 上一次性运行。任何临时补丁都使 T 结果失效，必须如实记录而不能“修好再看一次”。

9.5 P4: 成本、忠实度与写作

产出严格 $\text{pass}@k$ 主表、成本 Pareto、reuse 分布、曝光与晋升漏斗、代理忠实度审计、负结果和限制。论文不得把引用次数写成因因果价值，也不得声称不适用的理论保证。

A 核心字段契约

A.1 LibraryEntry

```
{
  "name": "sgs_lem_<content-hash>",
  "stmt": "...",
  "proof": "...",
  "verified": true,
  "source_corpus": "C2",
  "source_target": "C2:...",
  "status": "probation|active|cold",
  "reuse": 3,
  "reuse_targets": [...],
  "exposures": 8,
  "exposure_targets": [...],
  "cost_tokens": 24,
  "added_round": 2,
  "promoted_round": 4,
  "evicted_round": null
}
```

A.2 LibrarySnapshot

```
{  
  "version": "snapshot-...",  
  "sha256": "...",  
  "commit": "...",  
  "generated_at": "...",  
  "imports": ["Mathlib", "SgsLean.GeneratedLibrary"],  
  "active_names": ["sgs_lem_..."],  
  "corpus_hashes": {"C_build": "...", "C_measure": "..."},  
  "config": {"reuse_threshold": 2, "min_exposures": 4},  
  "build_ok": true,  
  "preflight_ok": true  
}
```

A.3 严格评测记录

```
{  
  "target": "...",  
  "snapshot_hash": "...",  
  "k": 4,  
  "strict": true,  
  "cheap_enabled": false,  
  "repair_rounds": 0,  
  "proofs_generated": 4,  
  "proofs_verified": 1,  
  "solved": true,  
  "verified_library_constants": ["sgs_lem_..."],  
  "usage": {"prompt_tokens": 0, "completion_tokens": 0},  
  "backend_error": null,  
  "protocol_error": null  
}
```